## Eksperimantiranje

Prvo ćemo importati potrebne pakete i fiksirati *random seed* kako bi kod bio reproducibilan.

```
In []: from enum import Enum
    from time import sleep

import pandas as pd
    import numpy as np
    from sklearn.decomposition import PCA
    from sklearn.cross_decomposition import PLSRegression
    from sklearn.linear_model import LinearRegression
    from sklearn.pipeline import make_pipeline
    from sklearn.model_selection import train_test_split
    from sklearn.preprocessing import StandardScaler
    from tqdm import tqdm

random_state = 42
rng = np.random.RandomState(random_state)
```

Sljedeća funkcija služi generiranju uzorka jediničnih normalnih veličina x i y td.

$$y=eta x+arepsilon, \ \ arepsilon \sim N(0,\sigma^2) \ \mathrm{Cov}(x_i,x_j)=\sigma^2>0, \ \ i
eq j.$$

Brzinski sanity check: ako je  $\rho = 0$ , tada je

$$\mathrm{Var}(y) = \sum_{k=0}^N eta_k^2 \mathrm{Var}(X_k) + \mathrm{Var}(arepsilon),$$

što bi u slucaju  $N=3, \beta=(1,\ldots,1)$  moralo biti 4. Zaista, za dovoljno velik uzorak imamo da je uzoračka varijanca  $\approx 4$ :

```
In []: N = 3
    beta = np.ones(3)
    rho = 0
    sample_size = 1000000

X, y = get_sample(beta=beta, rho=rho, sample_size=sample_size)
    print(f'>>> Var(y) = {y.var(ddof=1)}')

>>> Var(y) = 3.9966141119858167
```

Nastavljamo definiranjem funkcija za treniranje LS, PCR i PLS modela, pri čemu potonja dva kao parametar primaju i broj glavnih komponenti koje koriste.

```
In [ ]: class Model(str, Enum):
            linreg = "linreg"
            pcr = "pcr"
            pls = "pls"
            @staticmethod
            def train(model name: str, X: np.array, y: np.array, n components: int
                if model name not in list(Model):
                    raise ValueError(f'No such model. Available models are {list(Mod
                if model name == Model.linreg:
                    model = LinearRegression()
                elif model name == Model.pcr:
                    model = make pipeline(PCA(n components=n components, random stat
                elif model name == Model.pls:
                    model = PLSRegression(n components=n components)
                model.fit(X, y)
                return model
```

Jedan razuman način validacije naših modela bio bi da koristeći distribucije iz kojih smo generirali podatke izračunamo populacijski  $\beta$  pa za grešku modela uzmemo koliko se njegov koeficijent razlikuje od populacijskog, tj. ako je nas model dan s $y=\hat{\beta}x$ , njegovu grešku možemo računati kao

$$Err(Model) = \|\beta - \hat{\beta}\|.$$

Međutim, kako je prilikom visoke korelacije kovarijata taj  $\beta$  "nestabilan", mi ćemo umjesto toga testirati naše modele na velikom testnom uzorku. Preciznije, prvo ćemo izgenerirati jako velik uzorak, zatim trenirati model na njegovom malom dijelu, a na ostatku izračunati R2, što ce nam biti primarna metrika za validaciju modela. Takav pristup ima dvije prednosti:

- 1. Metrike poput kvaratne greške i R2 su interpretabilnije od udaljenosti do stvarnog  $\beta$ .
- 2. Tako se stvari rade u praksi (jer ne znamo stvarne distribucije pa ni vrijednost populacijskog koeficijenta); istrenira se model na uzorku koji nam je dan, a zatim validira na testnom skupu pa ide u produkciju.

Donji primjer pokazuje kako kod "skoro" nezavisnih kovarijata PLS bolje predviđa nego PCR. To je i očekivano, pogotovo ako je broj komponenti puno manji od N jer tada PCA nužno gubi bitne informacije za predviđanje. S druge strane, PLS, rastavljajuci zavisnu varijablu skupa s nezavisnima, ne izgubi gotovo ništa te predviđa jednako dobro kao i linearna regresija, ali u puno manjoj dimenziji pa je stoga interpretabilniji od nje.

Sad ćemo za razne parametre provesti eksperiment i podatke o R2 spremiti u datoteku scores.csv.

```
In []: SAMPLE_SIZE = 100_000

index_columns = ['train_sample_size', 'N', 'n_components', 'rho']
score_df = pd.DataFrame(None, columns=index_columns+[x.value for x in Model]

Ns = [500, 100, 50, 10, 5]
loader = tqdm(Ns)

N_train_sample_size_ratios = [10, 5, 3, 2, 1]
n_components_N_ratios = [0.01, 0.1, 0.25, 0.5]
rhos = [0.01, 0.1, 0.2, 0.5, 0.9, 0.99]

for N in loader:
    for rho in rhos:
```

```
beta = rng.normal(loc=0, scale=25, size=N)
X, y = get_sample(beta=beta, rho=rho, sample_size=SAMPLE_SIZE)

for train_sample_size in [N*x for x in N_train_sample_size_ratios]:
    X_train, X_test, y_train, y_test = train_test_split(X, y, random
    for n_components in [int(N*x) for x in n_components_N_ratios]:
        if n_components == 0:
            continue

        score_dict = train_and_evaluate_all_models(X_train=X_train, hparams_dict = dict(train_sample_size=train_sample_size, N=N new_row = hparams_dict | score_dict
        score_df.loc[len(score_df), :] = new_row
        loader.set_postfix(**new_row)

        score_df.to_csv('scores.csv', index=False)

score_df.to_csv('scores.csv', index=False)
```

100% | 5/5 [14:30<00:00, 174.03s/it, N=5, linreg=0.999, n\_compone nts=2, pcr=0.996, pls=0.997, rho=0.99, train\_sample\_size=5]